LAB 3

Luis Gonzalez, Joel Jaquez, Fabian Morales

2026-03-13

Librerías a utilizar

```r
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
library(ggplot2)
library(tidyr)
library(stringr)
library(readr)
library(nortest)
```

Cargar datos

```r
load("datos/listings.RData")
```

Análisis exploratorio

Descripción del Conjunto de Datos (Diccionario de Variables)

Variable	Tipo (R)	Clasificación Estadística	Descripción
id	num	Cualitativa Nominal	Identificador único de la propiedad en Airbnb.
listing_url	chr	Cualitativa Nominal	Enlace web a la publicación de la propiedad.
scrape_id	num	Cualitativa Nominal	Identificador único del proceso de extracción de datos.
last_scraped	chr	Cualitativa Ordinal	Fecha en la que se extrajo la información de esta propiedad.
source	chr	Cualitativa Nominal	Fuente de donde se obtuvo la información (ej. city scrape).
name	chr	Cualitativa Nominal	Título o nombre del anuncio de la propiedad.
description	chr	Cualitativa Nominal	Descripción detallada de la propiedad proporcionada por el anfitrión.
neighborhood_overview	chr	Cualitativa Nominal	Descripción del vecindario proporcionada por el anfitrión.
picture_url	chr	Cualitativa Nominal	Enlace a la imagen principal de la propiedad.
host_id	int	Cualitativa Nominal	Identificador único del anfitrión.
host_url	chr	Cualitativa Nominal	Enlace al perfil del anfitrión.
host_name	chr	Cualitativa Nominal	Nombre de pila del anfitrión.
host_since	chr	Cualitativa Ordinal	Fecha en la que el anfitrión se unió a la plataforma.
host_location	chr	Cualitativa Nominal	Ubicación declarada por el anfitrión en su perfil.
host_about	chr	Cualitativa Nominal	Descripción personal del anfitrión.
host_response_time	chr	Cualitativa Ordinal	Tiempo promedio que tarda el anfitrión en responder mensajes.
host_response_rate	chr	Cuantitativa Continua	Porcentaje de mensajes respondidos por el anfitrión (formato texto).
host_acceptance_rate	chr	Cuantitativa Continua	Porcentaje de solicitudes de reserva aceptadas (formato texto).

Variable	Tipo (R)	Clasificación Estadística	Descripción
host_is_superhost	chr	Cualitativa Nominal	Indica si el anfitrión tiene estatus de "Superhost" (t/f).
host_thumbnail_url	chr	Cualitativa Nominal	Enlace a la imagen en miniatura del perfil del anfitrión.
host_picture_url	chr	Cualitativa Nominal	Enlace a la imagen de perfil del anfitrión.
host_neighbourhood	chr	Cualitativa Nominal	Vecindario principal del anfitrión.
host_listings_count	int	Cuantitativa Discreta	Cantidad de propiedades que el anfitrión tiene listadas.
host_total_listings_count	int	Cuantitativa Discreta	Cantidad total histórica de propiedades del anfitrión.
host_verifications	chr	Cualitativa Nominal	Métodos por los cuales el anfitrión ha sido verificado (ej. email, teléfono).
host_has_profile_pic	chr	Cualitativa Nominal	Indica si el anfitrión tiene foto de perfil (t/f).
host_identity_verified	chr	Cualitativa Nominal	Indica si la identidad del anfitrión está verificada (t/f).
neighbourhood	chr	Cualitativa Nominal	Nombre general del vecindario.
neighbourhood_cleansed	chr	Cualitativa Nominal	Código postal o nombre estandarizado del vecindario.
neighbourhood_group_cleansed	chr	Cualitativa Nominal	Agrupación mayor de vecindarios (usualmente vacía en esta ciudad).
latitude	num	Cuantitativa Continua	Coordenada de latitud de la propiedad.
longitude	num	Cuantitativa Continua	Coordenada de longitud de la propiedad.
property_type	chr	Cualitativa Nominal	Categoría arquitectónica de la propiedad (ej. Casa, Apartamento).
room_type	chr	Cualitativa Nominal	Tipo de espacio alquilado (ej. Casa entera, Habitación privada).
accommodates	int	Cuantitativa Discreta	Capacidad máxima de huéspedes simultáneos en la propiedad.
bathrooms	num	Cuantitativa Discreta	Cantidad de baños disponibles.
bathrooms_text	chr	Cualitativa Nominal	Descripción en texto de la cantidad y tipo de baños (ej. "1.5 baths").

Variable	Tipo (R)	Clasificación Estadística	Descripción
bedrooms	int	Cuantitativa Discreta	Cantidad de habitaciones privadas en la propiedad.
beds	int	Cuantitativa Discreta	Cantidad total de camas en la propiedad.
amenities	chr	Cualitativa Nominal	Lista en formato JSON de las comodidades ofrecidas (WiFi, piscina, etc.).
price	chr	Cuantitativa Continua	Precio por noche. *(Variable Respuesta - Se lee como texto por el símbolo $).*
minimum_nights	int	Cuantitativa Discreta	Estancia mínima exigida (en noches).
maximum_nights	int	Cuantitativa Discreta	Estancia máxima permitida (en noches).
minimum_minimum_nights	int	Cuantitativa Discreta	El valor mínimo histórico configurado para estancia mínima.
maximum_minimum_nights	int	Cuantitativa Discreta	El valor máximo histórico configurado para estancia mínima.
minimum_maximum_nights	int	Cuantitativa Discreta	El valor mínimo histórico configurado para estancia máxima.
maximum_maximum_nights	int	Cuantitativa Discreta	El valor máximo histórico configurado para estancia máxima.
minimum_nights_avg_ntm	dbl	Cuantitativa Continua	Promedio móvil de noches mínimas exigidas.
maximum_nights_avg_ntm	dbl	Cuantitativa Continua	Promedio móvil de noches máximas permitidas.
calendar_updated	logi	Cualitativa Nominal	Indicador de última actualización del calendario (usualmente nulo).
has_availability	chr	Cualitativa Nominal	Indica si la propiedad tiene días disponibles en el calendario (t/f).
availability_30	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 30 días.
availability_60	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 60 días.
availability_90	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 90 días.

Variable	Tipo (R)	Clasificación Estadística	Descripción
availability_365	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 365 días.
calendar_last_scraped	chr	Cualitativa Ordinal	Fecha en la que se extrajo el calendario por última vez.
number_of_reviews	int	Cuantitativa Discreta	Total de reseñas acumuladas de la propiedad.
number_of_reviews_ltm	int	Cuantitativa Discreta	Reseñas recibidas en los últimos 12 meses (Last Twelve Months).
number_of_reviews_l30d	int	Cuantitativa Discreta	Reseñas recibidas en los últimos 30 días.
availability_eoy	int	Cuantitativa Discreta	Disponibilidad calculada hacia el final del año.
number_of_reviews_ly	int	Cuantitativa Discreta	Reseñas recibidas el año anterior.
estimated_occupancy_l365d	int	Cuantitativa Discreta	Días estimados de ocupación en el último año.
estimated_revenue_l365d	num	Cuantitativa Continua	Ingresos estimados generados en el último año.
first_review	chr	Cualitativa Ordinal	Fecha de la primera reseña recibida.
last_review	chr	Cualitativa Ordinal	Fecha de la última reseña recibida.
review_scores_rating	num	Cuantitativa Continua	Calificación general promedio otorgada por los huéspedes.
review_scores_accuracy	num	Cuantitativa Continua	Calificación específica sobre la precisión del anuncio.
review_scores_cleanliness	num	Cuantitativa Continua	Calificación específica sobre la limpieza de la propiedad.
review_scores_checkin	num	Cuantitativa Continua	Calificación específica sobre el proceso de llegada.
review_scores_communication	num	Cuantitativa Continua	Calificación específica sobre la comunicación con el anfitrión.
review_scores_location	num	Cuantitativa Continua	Calificación específica sobre la ubicación de la propiedad.
review_scores_value	num	Cuantitativa Continua	Calificación específica sobre la relación calidad-precio.
license	chr	Cualitativa Nominal	Número de licencia comercial de la propiedad (si aplica).

Variable	Tipo (R)	Clasificación Estadística	Descripción
instant_bookable	chr	Cualitativa Nominal	Indica si la propiedad permite reserva inmediata sin preaprobación (t/f).
calculated_host_listings_count	int	Cuantitativa Discreta	Cantidad de propiedades de este anfitrión en esta ciudad específica.
calculated_host_listings_count_entire_homes	int	Cuantitativa Discreta	Cantidad de casas enteras de este anfitrión.
calculated_host_listings_count_private_rooms	int	Cuantitativa Discreta	Cantidad de habitaciones privadas de este anfitrión.
calculated_host_listings_count_shared_rooms	int	Cuantitativa Discreta	Cantidad de habitaciones compartidas de este anfitrión.
reviews_per_month	num	Cuantitativa Continua	Promedio de reseñas recibidas por mes.
city	chr	Cualitativa Nominal	Ciudad principal donde se encuentra la propiedad.

> **Nota sobre el preprocesamiento:** En la tabla anterior se evidencia que diversas variables cuantitativas (como `price`, `host_response_rate` y `host_acceptance_rate`) fueron interpretadas por R como texto (`chr`) debido a la inclusión de símbolos de moneda o porcentajes. Asimismo, existen numerosas variables de identificación (URLs, IDs) que son irrelevantes para un modelo predictivo. Esta clasificación justifica las acciones de limpieza tomadas en la siguiente sección.

Preprocesamiento inicial

```r
listings_clean <- listings %>%
  # Limpieza de la variable predictora (price)
  # parse_number extrae el número sin importar los símbolos raros que tenga el texto
  mutate(price = parse_number(price)) %>%

  # Eliminación de variables innecesarias (IDs puros, URLs y texto libre extenso)
  select(-c(listing_url, scrape_id, picture_url, host_url, host_thumbnail_url,
            host_picture_url, description, neighborhood_overview, host_about, amenities))
```

Para poder entrenar algoritmos predictivos, es un requisito indispensable que la variable respuesta sea numérica. Por ello, se realicé una transformación en la columna price, adicionalmente se descartaron columnas de identificadores únicos y enlaces web, ya que estas características introducen ruido y no poseen poder predictivo generalizable para estimar el valor de una vivienda.

Exploración rápida de dimensiones

```r
dim(listings_clean)
```

```
## [1] 171748     70
```

Para este primer paso, utilizamos la función dim() en nuestro conjunto de datos ya limpio. Como podemos observar, el dataset cuenta con 171,748 observaciones que son filas y reducimos las características a 70 variables que son las columnas. Esto significa que tenemos una base robusta de propiedades de Airbnb para analizar y así poder hacer modelos predictivos eficientes.

Análisis de la Variable Objetivo (Precio)

```r
# Histograma filtrando valores atípicos para mejor visualización
listings_clean %>%
  filter(!is.na(price), price < 1000) %>%
  ggplot(aes(x = price)) +
  geom_histogram(bins = 40, fill = "#2E8B57", color = "white") +
  labs(title = "Distribución de Precios (Propiedades < $1,000/noche)",
       x = "Precio ($)",
       y = "Cantidad de Propiedades") +
  theme_minimal()
```

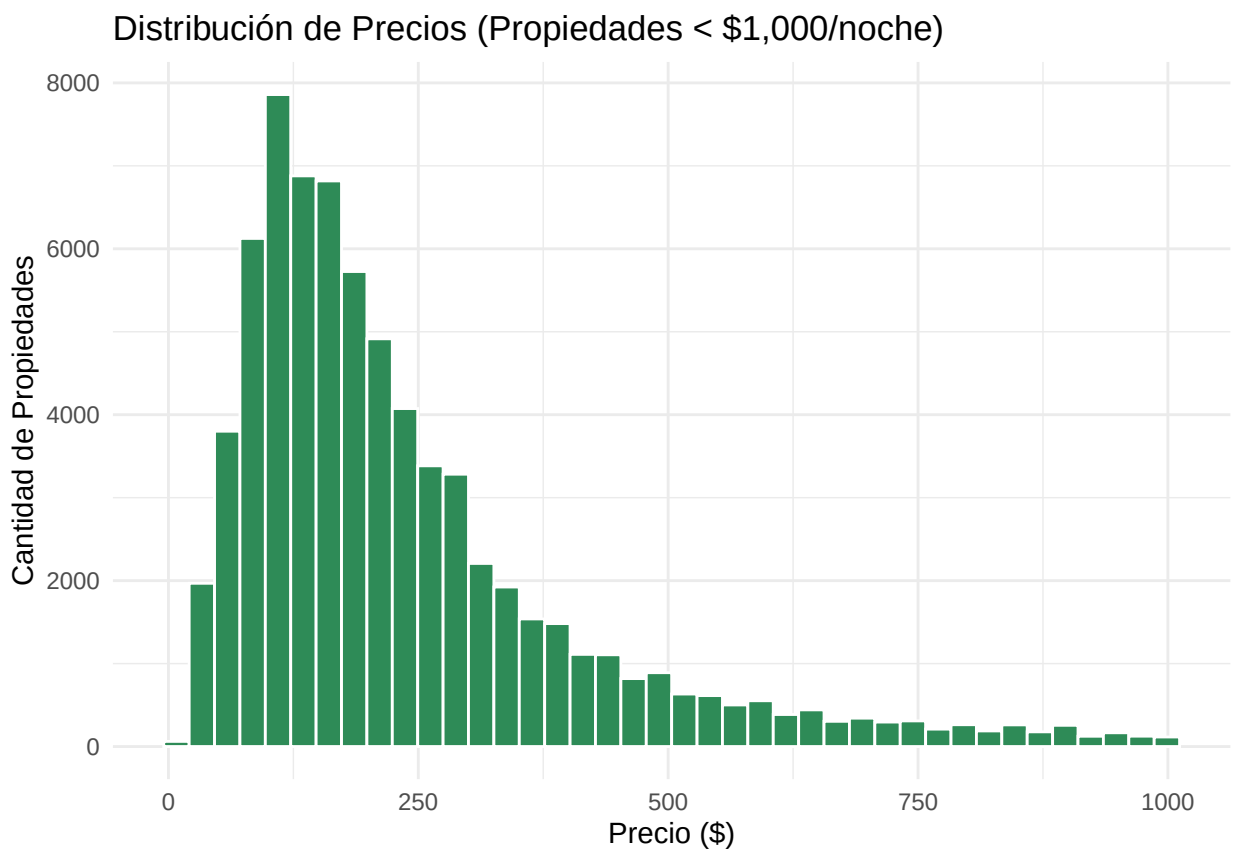

Al remover los valores atípicos (precios superiores a 1,000) y los datos nulos, la verdadera distribución del mercado se hace visible. Se observa una fuerte asimetría positiva (sesgo a la derecha), indicando que la gran

mayoría de las propiedades listadas por SmartStay Advisors se concentran en un rango de precios accesible, predominantemente entre los 50 y 250 por noche. Esta asimetría sugiere que, al momento de entrenar nuestros modelos de regresión lineal, probablemente será beneficioso aplicar una transformación (como el logaritmo) a la variable precio para normalizar su distribución, cumplir con los supuestos estadísticos y mejorar el ajuste del algoritmo.

Análisis de la Variable Objetivo (Precio)

```r
# Extraer los precios válidos (sin NAs)
precios_validos <- na.omit(listings_clean$price)

# Tomar una muestra aleatoria de 5000 datos
# (lillie.test no soporta más de 5000 observaciones)
set.seed(123)
muestra_precio <- sample(precios_validos, 5000)

# prueba de Lilliefors
lillie.test(muestra_precio)
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  muestra_precio
## D = 0.43045, p-value < 2.2e-16
```

Al aplicar la prueba de normalidad de Lilliefors sobre una muestra aleatoria de 5,000 registros de la variable `price`, obtuvimos un p-value de `< 2.2e-16`, el cual es significativamente menor al nivel de significancia estándar de 0.05. Por lo tanto, se rechaza la hipótesis nula y se comprueba estadísticamente que los precios de las propiedades no siguen una distribución normal. Este resultado matemático respalda el comportamiento asimétrico (sesgo a la derecha) observado previamente en el histograma. Para la construcción de nuestro modelo de regresión lineal múltiple, este hallazgo es crucial, ya que nos indica que será necesario aplicar transformaciones (como el logaritmo natural) a la variable respuesta para cumplir con los supuestos del algoritmo.

Precio vs Capacidad

```r
# Relación entre la capacidad de personas y el precio
listings_clean %>%
  # Filtramos precios atípicos y valores nulos
  filter(!is.na(price), price < 1000, !is.na(accommodates)) %>%
  ggplot(aes(x = factor(accommodates), y = price)) +
  geom_boxplot(fill = "#FF8C00", alpha = 0.7, outlier.color = "red", outlier.size = 1) +
  labs(title = "Relación entre Capacidad de la Propiedad y Precio",
       x = "Capacidad (Cantidad de Personas)",
       y = "Precio por Noche ($)") +
  theme_minimal()
```

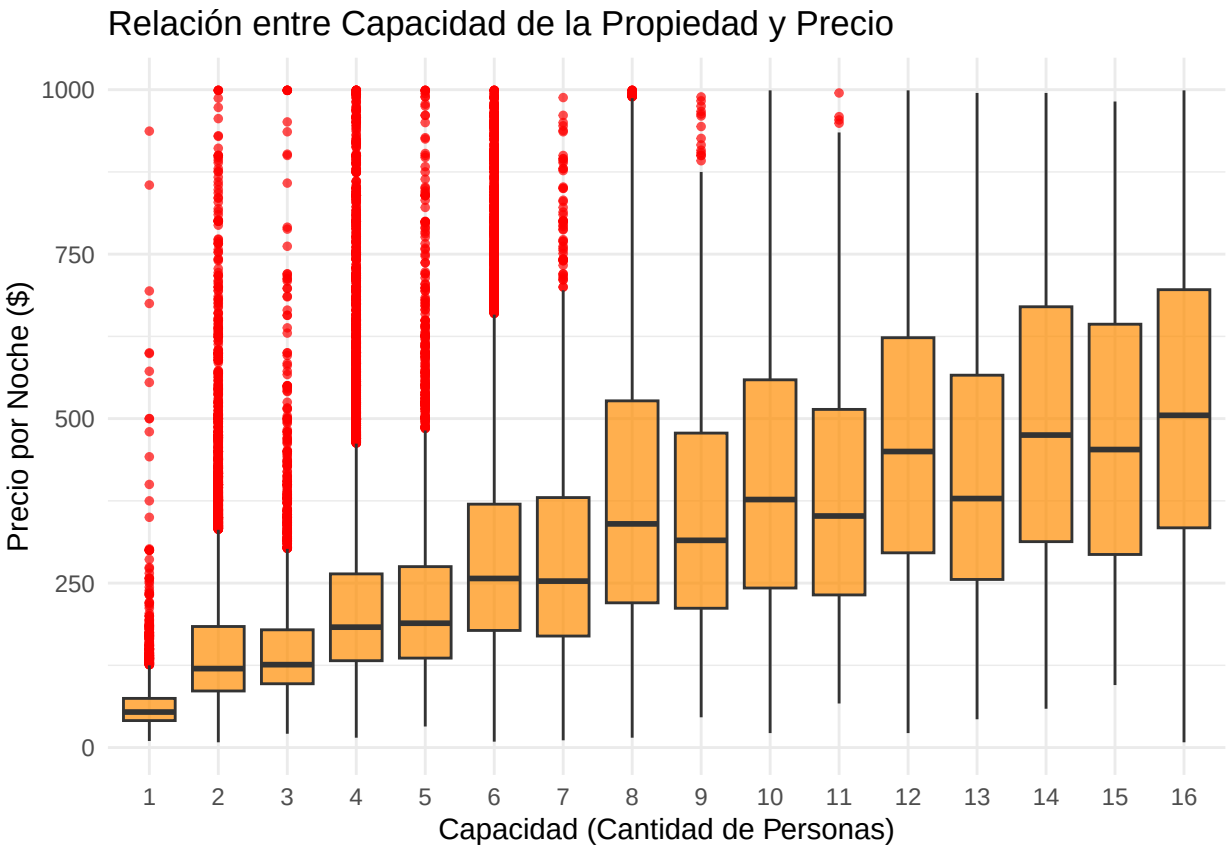

Al analizar la relación entre la capacidad de huéspedes (accommodates) y el precio por noche (price), se observa una clara tendencia positiva donde la mediana del costo incrementa conforme aumenta la capacidad de la propiedad. Sin embargo, el diagrama de caja revela una alta concentración de valores atípicos (precios premium cercanos a los $1,000) en alojamientos pequeños para 2 a 6 personas, lo que indica que características adicionales como una ubicación exclusiva o amenidades de lujo pueden inflar el valor sin requerir más espacio. Asimismo, las propiedades grandes (10 o más personas) presentan una gran variabilidad y dispersión en sus tarifas, abarcando desde opciones accesibles hasta rentas muy costosas. Por lo tanto, aunque la capacidad es un predictor fuerte e indispensable para estimar el valor de una vivienda, esta alta dispersión hace estrictamente necesario combinarla con otras variables del conjunto de datos para que el modelo predictivo logre resultados precisos.