LAB 3

Luis Gonzalez, Joel Jaquez, Fabian Morales

2026-03-13

Librerías a utilizar

```r
library(dplyr)
```

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union
```

```r
library(ggplot2)
library(tidyr)
library(stringr)
library(readr)
library(nortest)
```

Cargar datos

```r
load("datos/listings.RData")
```

Análisis exploratorio

Descripción del Conjunto de Datos (Diccionario de Variables)

Variable	Tipo (R)	Clasificación Estadística	Descripción
id	num	Cualitativa Nominal	Identificador único de la propiedad en Airbnb.
listing_url	chr	Cualitativa Nominal	Enlace web a la publicación de la propiedad.
scrape_id	num	Cualitativa Nominal	Identificador único del proceso de extracción de datos.
last_scraped	chr	Cualitativa Ordinal	Fecha en la que se extrajo la información de esta propiedad.
source	chr	Cualitativa Nominal	Fuente de donde se obtuvo la información (ej. city scrape).
name	chr	Cualitativa Nominal	Título o nombre del anuncio de la propiedad.
description	chr	Cualitativa Nominal	Descripción detallada de la propiedad proporcionada por el anfitrión.
neighborhood_overview	chr	Cualitativa Nominal	Descripción del vecindario proporcionada por el anfitrión.
picture_url	chr	Cualitativa Nominal	Enlace a la imagen principal de la propiedad.
host_id	int	Cualitativa Nominal	Identificador único del anfitrión.
host_url	chr	Cualitativa Nominal	Enlace al perfil del anfitrión.
host_name	chr	Cualitativa Nominal	Nombre de pila del anfitrión.
host_since	chr	Cualitativa Ordinal	Fecha en la que el anfitrión se unió a la plataforma.
host_location	chr	Cualitativa Nominal	Ubicación declarada por el anfitrión en su perfil.
host_about	chr	Cualitativa Nominal	Descripción personal del anfitrión.
host_response_time	chr	Cualitativa Ordinal	Tiempo promedio que tarda el anfitrión en responder mensajes.
host_response_rate	chr	Cuantitativa Continua	Porcentaje de mensajes respondidos por el anfitrión (formato texto).
host_acceptance_rate	chr	Cuantitativa Continua	Porcentaje de solicitudes de reserva aceptadas (formato texto).

Variable	Tipo (R)	Clasificación Estadística	Descripción
host_is_superhost	chr	Cualitativa Nominal	Indica si el anfitrión tiene estatus de "Superhost" (t/f).
host_thumbnail_url	chr	Cualitativa Nominal	Enlace a la imagen en miniatura del perfil del anfitrión.
host_picture_url	chr	Cualitativa Nominal	Enlace a la imagen de perfil del anfitrión.
host_neighbourhood	chr	Cualitativa Nominal	Vecindario principal del anfitrión.
host_listings_count	int	Cuantitativa Discreta	Cantidad de propiedades que el anfitrión tiene listadas.
host_total_listings_count	int	Cuantitativa Discreta	Cantidad total histórica de propiedades del anfitrión.
host_verifications	chr	Cualitativa Nominal	Métodos por los cuales el anfitrión ha sido verificado (ej. email, teléfono).
host_has_profile_pic	chr	Cualitativa Nominal	Indica si el anfitrión tiene foto de perfil (t/f).
host_identity_verified	chr	Cualitativa Nominal	Indica si la identidad del anfitrión está verificada (t/f).
neighbourhood	chr	Cualitativa Nominal	Nombre general del vecindario.
neighbourhood_cleansed	chr	Cualitativa Nominal	Código postal o nombre estandarizado del vecindario.
neighbourhood_group_cleansed	chr	Cualitativa Nominal	Agrupación mayor de vecindarios (usualmente vacía en esta ciudad).
latitude	num	Cuantitativa Continua	Coordenada de latitud de la propiedad.
longitude	num	Cuantitativa Continua	Coordenada de longitud de la propiedad.
property_type	chr	Cualitativa Nominal	Categoría arquitectónica de la propiedad (ej. Casa, Apartamento).
room_type	chr	Cualitativa Nominal	Tipo de espacio alquilado (ej. Casa entera, Habitación privada).
accommodates	int	Cuantitativa Discreta	Capacidad máxima de huéspedes simultáneos en la propiedad.
bathrooms	num	Cuantitativa Discreta	Cantidad de baños disponibles.
bathrooms_text	chr	Cualitativa Nominal	Descripción en texto de la cantidad y tipo de baños (ej. "1.5 baths").

Variable	Tipo (R)	Clasificación Estadística	Descripción
bedrooms	int	Cuantitativa Discreta	Cantidad de habitaciones privadas en la propiedad.
beds	int	Cuantitativa Discreta	Cantidad total de camas en la propiedad.
amenities	chr	Cualitativa Nominal	Lista en formato JSON de las comodidades ofrecidas (WiFi, piscina, etc.).
price	chr	Cuantitativa Continua	Precio por noche. *(Variable Respuesta - Se lee como texto por el símbolo $).*
minimum_nights	int	Cuantitativa Discreta	Estancia mínima exigida (en noches).
maximum_nights	int	Cuantitativa Discreta	Estancia máxima permitida (en noches).
minimum_minimum_nights	int	Cuantitativa Discreta	El valor mínimo histórico configurado para estancia mínima.
maximum_minimum_nights	int	Cuantitativa Discreta	El valor máximo histórico configurado para estancia mínima.
minimum_maximum_nights	int	Cuantitativa Discreta	El valor mínimo histórico configurado para estancia máxima.
maximum_maximum_nights	int	Cuantitativa Discreta	El valor máximo histórico configurado para estancia máxima.
minimum_nights_avg_ntm	dbl	Cuantitativa Continua	Promedio móvil de noches mínimas exigidas.
maximum_nights_avg_ntm	dbl	Cuantitativa Continua	Promedio móvil de noches máximas permitidas.
calendar_updated	logi	Cualitativa Nominal	Indicador de última actualización del calendario (usualmente nulo).
has_availability	chr	Cualitativa Nominal	Indica si la propiedad tiene días disponibles en el calendario (t/f).
availability_30	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 30 días.
availability_60	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 60 días.
availability_90	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 90 días.

Variable	Tipo (R)	Clasificación Estadística	Descripción
availability_365	int	Cuantitativa Discreta	Noches disponibles para reserva en los próximos 365 días.
calendar_last_scraped	chr	Cualitativa Ordinal	Fecha en la que se extrajo el calendario por última vez.
number_of_reviews	int	Cuantitativa Discreta	Total de reseñas acumuladas de la propiedad.
number_of_reviews_ltm	int	Cuantitativa Discreta	Reseñas recibidas en los últimos 12 meses (Last Twelve Months).
number_of_reviews_l30d	int	Cuantitativa Discreta	Reseñas recibidas en los últimos 30 días.
availability_eoy	int	Cuantitativa Discreta	Disponibilidad calculada hacia el final del año.
number_of_reviews_ly	int	Cuantitativa Discreta	Reseñas recibidas el año anterior.
estimated_occupancy_l365d	int	Cuantitativa Discreta	Días estimados de ocupación en el último año.
estimated_revenue_l365d	num	Cuantitativa Continua	Ingresos estimados generados en el último año.
first_review	chr	Cualitativa Ordinal	Fecha de la primera reseña recibida.
last_review	chr	Cualitativa Ordinal	Fecha de la última reseña recibida.
review_scores_rating	num	Cuantitativa Continua	Calificación general promedio otorgada por los huéspedes.
review_scores_accuracy	num	Cuantitativa Continua	Calificación específica sobre la precisión del anuncio.
review_scores_cleanliness	num	Cuantitativa Continua	Calificación específica sobre la limpieza de la propiedad.
review_scores_checkin	num	Cuantitativa Continua	Calificación específica sobre el proceso de llegada.
review_scores_communication	num	Cuantitativa Continua	Calificación específica sobre la comunicación con el anfitrión.
review_scores_location	num	Cuantitativa Continua	Calificación específica sobre la ubicación de la propiedad.
review_scores_value	num	Cuantitativa Continua	Calificación específica sobre la relación calidad-precio.
license	chr	Cualitativa Nominal	Número de licencia comercial de la propiedad (si aplica).

Variable	Tipo (R)	Clasificación Estadística	Descripción
instant_bookable	chr	Cualitativa Nominal	Indica si la propiedad permite reserva inmediata sin preaprobación (t/f).
calculated_host_listings_count	int	Cuantitativa Discreta	Cantidad de propiedades de este anfitrión en esta ciudad específica.
calculated_host_listings_count_entire_homes	int	Cuantitativa Discreta	Cantidad de casas enteras de este anfitrión.
calculated_host_listings_count_private_rooms	int	Cuantitativa Discreta	Cantidad de habitaciones privadas de este anfitrión.
calculated_host_listings_count_shared_rooms	int	Cuantitativa Discreta	Cantidad de habitaciones compartidas de este anfitrión.
reviews_per_month	num	Cuantitativa Continua	Promedio de reseñas recibidas por mes.
city	chr	Cualitativa Nominal	Ciudad principal donde se encuentra la propiedad.

> **Nota sobre el preprocesamiento:** En la tabla anterior se evidencia que diversas variables cuantitativas (como `price`, `host_response_rate` y `host_acceptance_rate`) fueron interpretadas por R como texto (`chr`) debido a la inclusión de símbolos de moneda o porcentajes. Asimismo, existen numerosas variables de identificación (URLs, IDs) que son irrelevantes para un modelo predictivo. Esta clasificación justifica las acciones de limpieza tomadas en la siguiente sección.

Preprocesamiento inicial

```r
listings_clean <- listings %>%
  # Limpieza de la variable predictora (price)
  # parse_number extrae el número sin importar los símbolos raros que tenga el texto
  mutate(price = parse_number(price)) %>%

  # Eliminación de variables innecesarias (IDs puros, URLs y texto libre extenso)
  select(-c(listing_url, scrape_id, picture_url, host_url, host_thumbnail_url,
            host_picture_url, description, neighborhood_overview, host_about, amenities))
```

Para poder entrenar algoritmos predictivos, es un requisito indispensable que la variable respuesta sea numérica. Por ello, se realicé una transformación en la columna price, adicionalmente se descartaron columnas de identificadores únicos y enlaces web, ya que estas características introducen ruido y no poseen poder predictivo generalizable para estimar el valor de una vivienda.

Exploración rápida de dimensiones

```r
dim(listings_clean)
```

```
## [1] 171748     70
```

Para este primer paso, utilizamos la función dim() en nuestro conjunto de datos ya limpio. Como podemos observar, el dataset cuenta con 171,748 observaciones que son filas y reducimos las características a 70 variables que son las columnas. Esto significa que tenemos una base robusta de propiedades de Airbnb para analizar y así poder hacer modelos predictivos eficientes.

Análisis de la Variable Objetivo (Precio)

```r
# Histograma filtrando valores atípicos para mejor visualización
listings_clean %>%
  filter(!is.na(price), price < 1000) %>%
  ggplot(aes(x = price)) +
  geom_histogram(bins = 40, fill = "#2E8B57", color = "white") +
  labs(title = "Distribución de Precios (Propiedades < $1,000/noche)",
       x = "Precio ($)",
       y = "Cantidad de Propiedades") +
  theme_minimal()
```

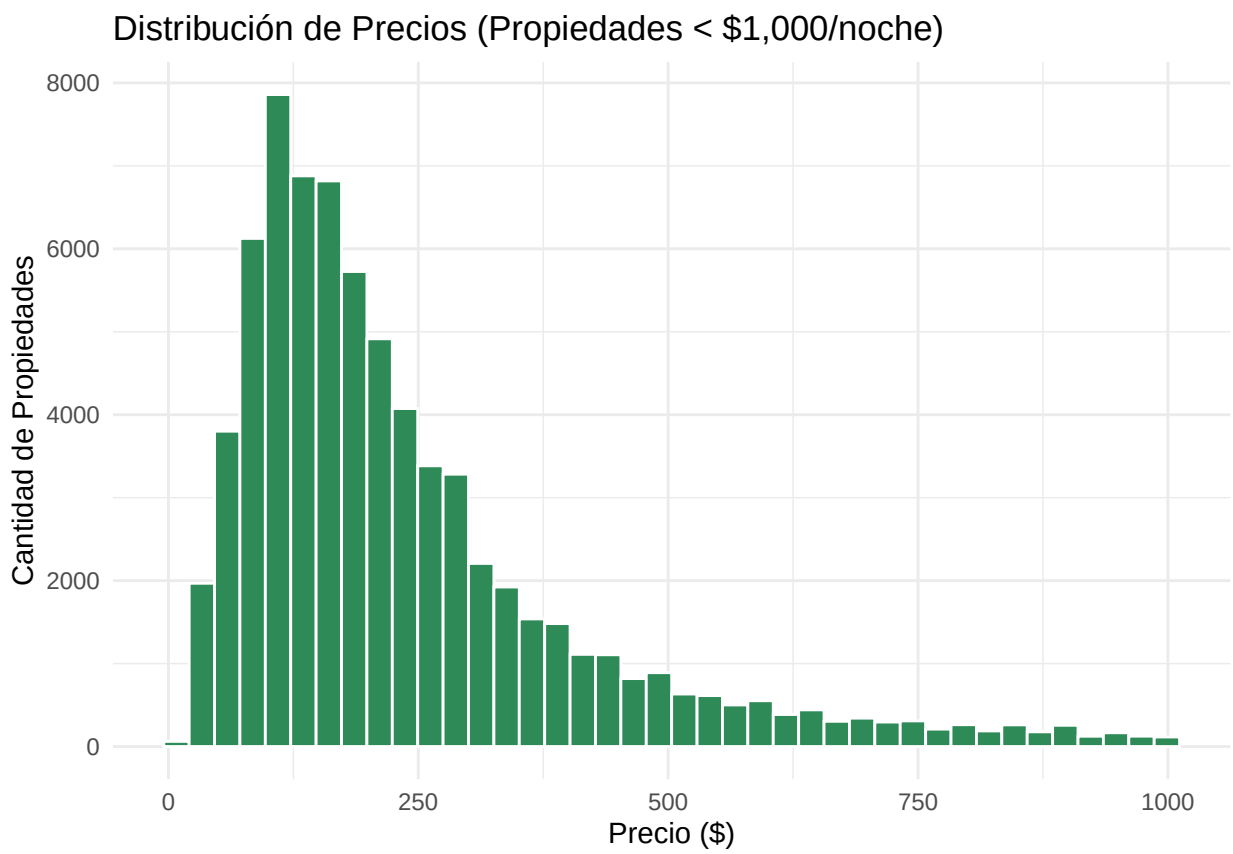

Al remover los valores atípicos (precios superiores a 1,000) y los datos nulos, la verdadera distribución del mercado se hace visible. Se observa una fuerte asimetría positiva (sesgo a la derecha), indicando que la gran

mayoría de las propiedades listadas por SmartStay Advisors se concentran en un rango de precios accesible, predominantemente entre los 50 y 250 por noche. Esta asimetría sugiere que, al momento de entrenar nuestros modelos de regresión lineal, probablemente será beneficioso aplicar una transformación (como el logaritmo) a la variable precio para normalizar su distribución, cumplir con los supuestos estadísticos y mejorar el ajuste del algoritmo.

Análisis de la Variable Objetivo (Precio)

```r
# Extraer los precios válidos (sin NAs)
precios_validos <- na.omit(listings_clean$price)

# Tomar una muestra aleatoria de 5000 datos
# (lillie.test no soporta más de 5000 observaciones)
set.seed(123)
muestra_precio <- sample(precios_validos, 5000)

# prueba de Lilliefors
lillie.test(muestra_precio)
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  muestra_precio
## D = 0.43045, p-value < 2.2e-16
```

Al aplicar la prueba de normalidad de Lilliefors sobre una muestra aleatoria de 5,000 registros de la variable `price`, obtuvimos un p-value de `< 2.2e-16`, el cual es significativamente menor al nivel de significancia estándar de 0.05. Por lo tanto, se rechaza la hipótesis nula y se comprueba estadísticamente que los precios de las propiedades no siguen una distribución normal. Este resultado matemático respalda el comportamiento asimétrico (sesgo a la derecha) observado previamente en el histograma. Para la construcción de nuestro modelo de regresión lineal múltiple, este hallazgo es crucial, ya que nos indica que será necesario aplicar transformaciones (como el logaritmo natural) a la variable respuesta para cumplir con los supuestos del algoritmo.

Precio vs Capacidad

```r
# Relación entre la capacidad de personas y el precio
listings_clean %>%
  # Filtramos precios atípicos y valores nulos
  filter(!is.na(price), price < 1000, !is.na(accommodates)) %>%
  ggplot(aes(x = factor(accommodates), y = price)) +
  geom_boxplot(fill = "#FF8C00", alpha = 0.7, outlier.color = "red", outlier.size = 1) +
  labs(title = "Relación entre Capacidad de la Propiedad y Precio",
       x = "Capacidad (Cantidad de Personas)",
       y = "Precio por Noche ($)") +
  theme_minimal()
```

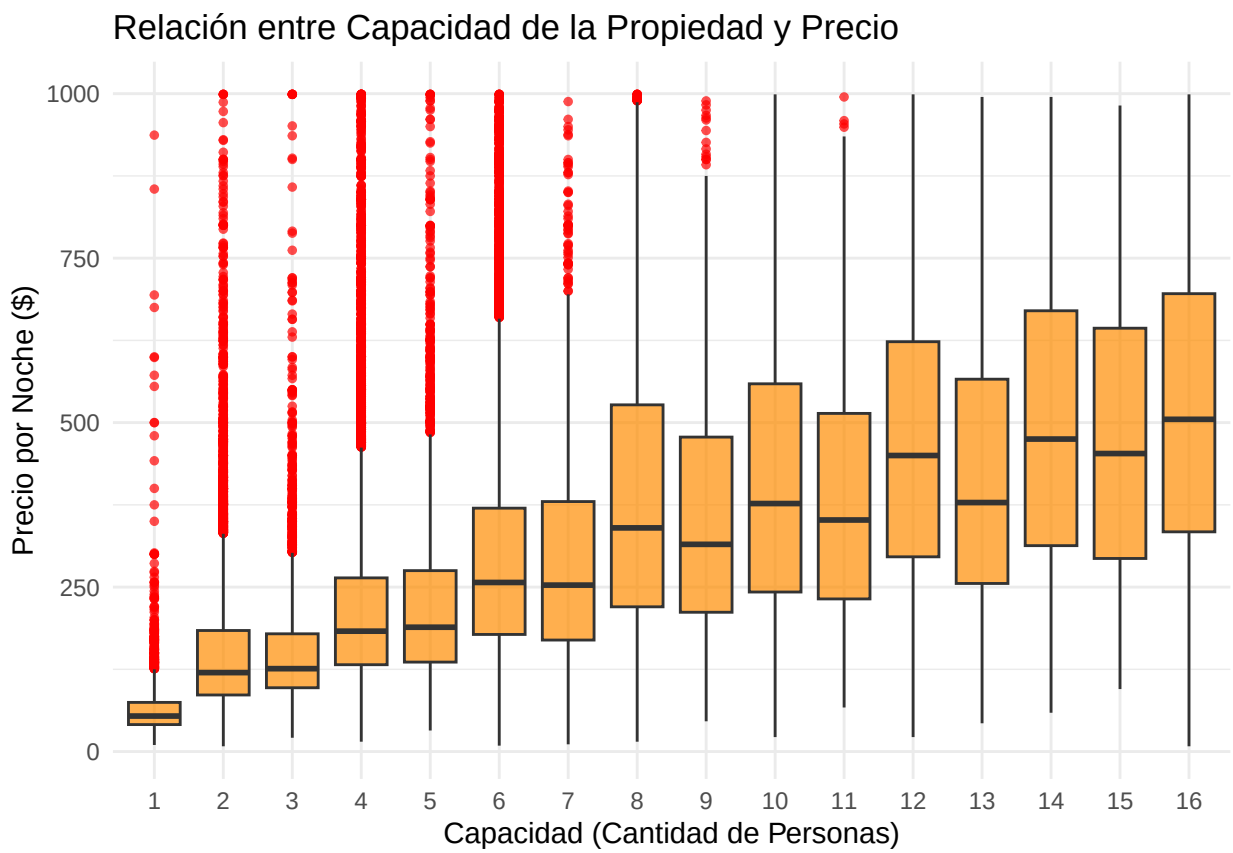

Al analizar la relación entre la capacidad de huéspedes (accommodates) y el precio por noche (price), se observa una clara tendencia positiva donde la mediana del costo incrementa conforme aumenta la capacidad de la propiedad. Sin embargo, el diagrama de caja revela una alta concentración de valores atípicos (precios premium cercanos a los $1,000) en alojamientos pequeños para 2 a 6 personas, lo que indica que características adicionales como una ubicación exclusiva o amenidades de lujo pueden inflar el valor sin requerir más espacio. Asimismo, las propiedades grandes (10 o más personas) presentan una gran variabilidad y dispersión en sus tarifas, abarcando desde opciones accesibles hasta rentas muy costosas. Por lo tanto, aunque la capacidad es un predictor fuerte e indispensable para estimar el valor de una vivienda, esta alta dispersión hace estrictamente necesario combinarla con otras variables del conjunto de datos para que el modelo predictivo logre resultados precisos.

Frecuencias

```r
# --- ANÁLISIS DE ROOM TYPE ---
# Tabla de resumen
room_summary <- listings_clean %>%
  filter(!is.na(price)) %>%
  group_by(room_type) %>%
  summarise(Cantidad = n(), Precio_Promedio = mean(price, na.rm = TRUE)) %>%
  arrange(desc(Cantidad))

print(room_summary)
```

```
## # A tibble: 4 x 3
```

```
##   room_type       Cantidad Precio_Promedio
##   <chr>              <int>           <dbl>
## 1 Entire home/apt    65709            505.
## 2 Private room        9673            839.
## 3 Hotel room           649          24477.
## 4 Shared room          215            149.
```

```
# Gráfico de frecuencias por room_type
ggplot(room_summary, aes(x = reorder(room_type, -Cantidad), y = Cantidad, fill = room_type)) +
  geom_col() +
  theme_minimal() +
  labs(title = "Frecuencia por Tipo de Cuarto", x = "Tipo de Cuarto", y = "Cantidad")
```

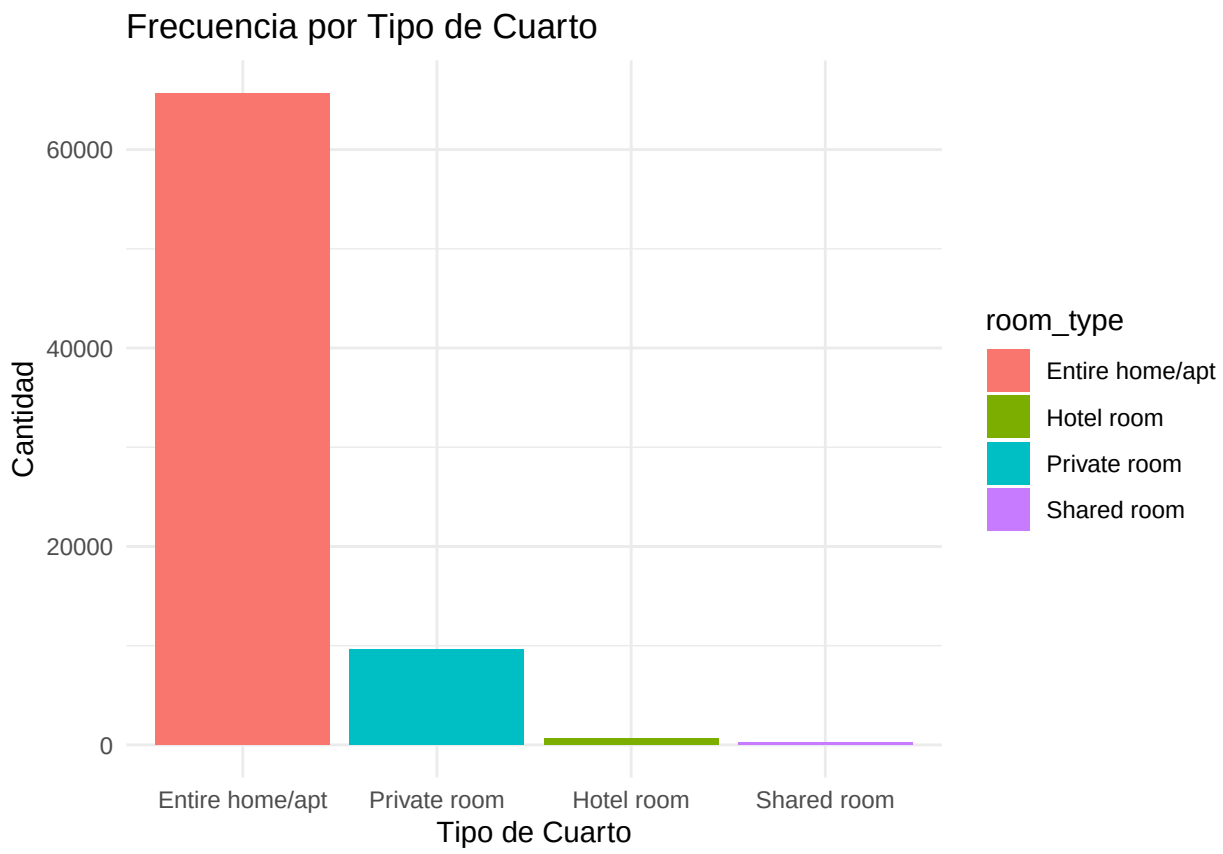


```
# Gráfico de precios promedio por room_type
ggplot(room_summary, aes(x = reorder(room_type, -Precio_Promedio), y = Precio_Promedio, fill = room_typ
  geom_col() +
  theme_minimal() +
  labs(title = "Precio Promedio por Tipo de Cuarto", x = "Tipo de Cuarto", y = "Precio Promedio ($)")
```

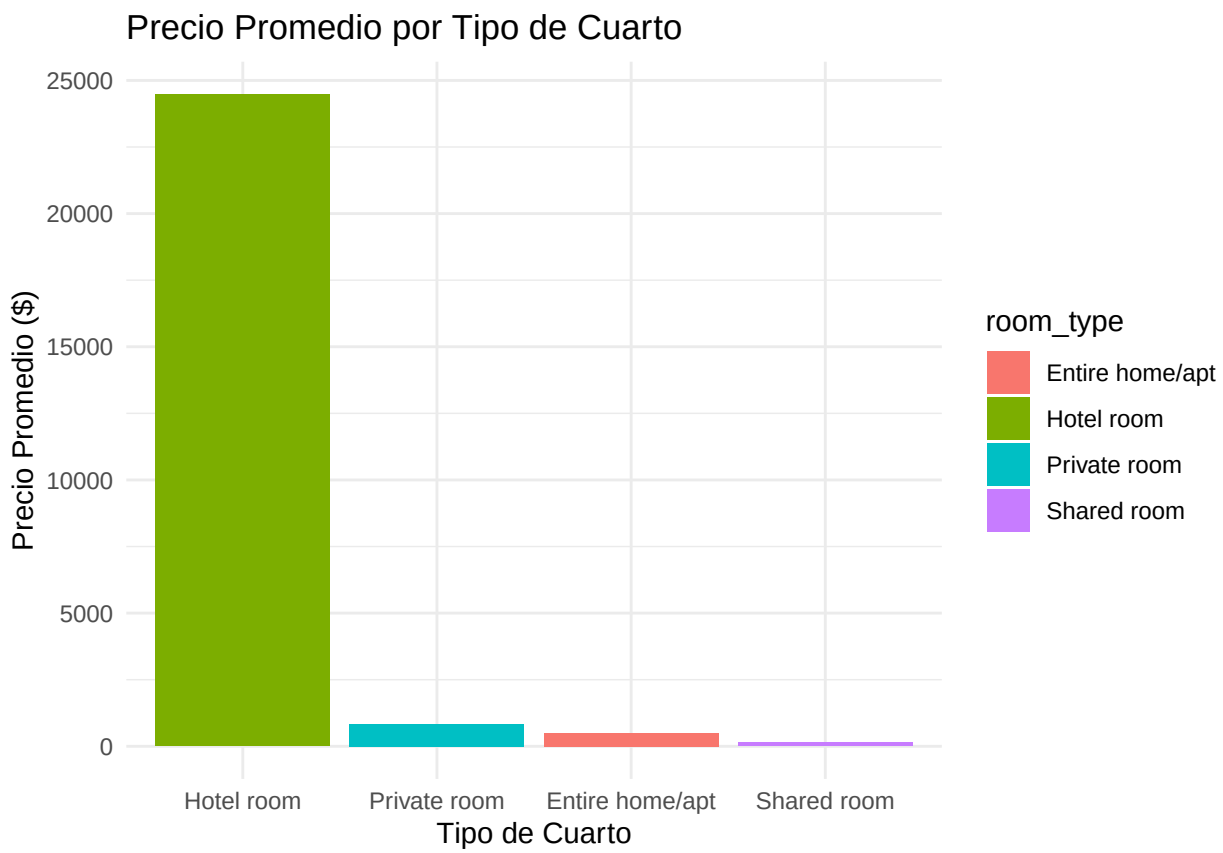


```r
# --- ANÁLISIS DE PROPERTY TYPE (TOP 10) ---
# Tabla de resumen
property_summary <- listings_clean %>%
  filter(!is.na(price)) %>%
  group_by(property_type) %>%
  summarise(Cantidad = n(), Precio_Promedio = mean(price, na.rm = TRUE)) %>%
  arrange(desc(Cantidad)) %>%
  head(10)

print(property_summary)
```

```
## # A tibble: 10 x 3
##    property_type               Cantidad Precio_Promedio
##    <chr>                          <int>           <dbl>
##  1 Entire rental unit             20403           291.
##  2 Entire condo                   19552           416.
##  3 Entire home                    16273           453.
##  4 Private room in home            3654            90.7
##  5 Private room in rental unit     2056            85.2
##  6 Room in hotel                   1963         11115.
##  7 Entire guesthouse               1681           146.
##  8 Entire townhouse                1617           348.
##  9 Entire guest suite              1595           137.
## 10 Entire serviced apartment       1024          9047.
```

```r
# Gráfico de frecuencias por property_type
ggplot(property_summary, aes(x = reorder(property_type, Cantidad), y = Cantidad, fill = property_type))
  geom_col() +
  coord_flip() +
  theme_minimal() +
  theme(legend.position = "none") +
  labs(title = "Top 10 Tipos de Propiedad mas Frecuentes", x = "Tipo de Propiedad", y = "Cantidad")
```

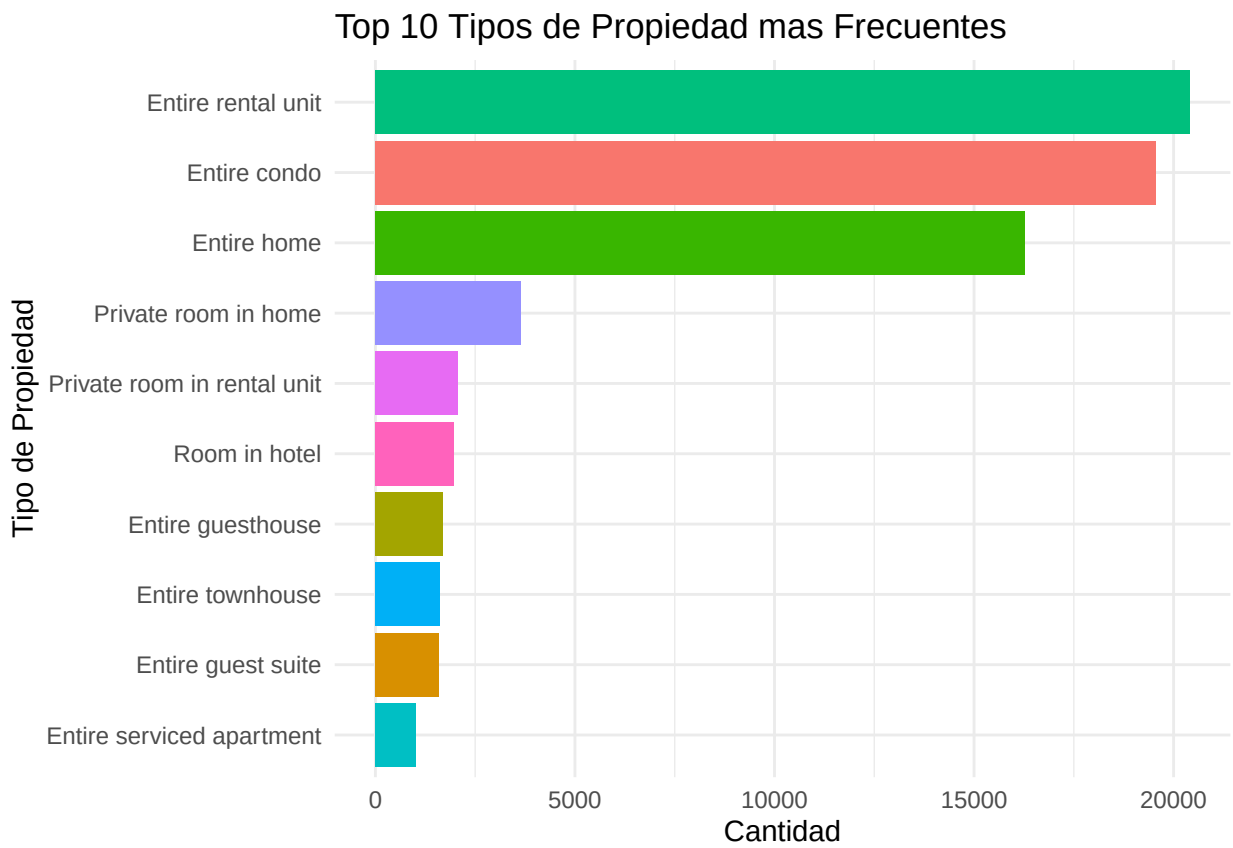

Revisando los resultados, nos dimos cuenta de que la plataforma está dominada por los espacios completos; el tipo de cuarto que más abunda, por mucho, es el Entire home/apt con más de 65,000 anuncios, y si miramos el tipo de propiedad específico, lo que más predomina son las unidades de alquiler (Entire rental unit), los condominios y las casas enteras. Lo más loco de los datos salta cuando vemos los precios promedio: aunque casi no hay cuartos de hotel (Hotel room), estos resultan ser exageradamente caros, promediando casi los $24,500 por noche. Esto seguro pasa porque hay un par de valores atípicos o propiedades de súper lujo que nos están inflando el promedio de forma brutal, mientras que rentar un apartamento entero o un cuarto privado maneja precios mucho más lógicos y reales para el mercado.

Superhost

```r
# --- BOXPLOT: SUPERHOST VS PRICE ---
listings_clean %>%
  # Filtramos NA en precio, valores atipicos, y NA en el estatus de superhost
  filter(!is.na(price), price < 1000, host_is_superhost %in% c("t", "f")) %>%
  ggplot(aes(x = host_is_superhost, y = price, fill = host_is_superhost)) +
```

```r
  geom_boxplot(alpha = 0.7, outlier.color = "red", outlier.size = 1) +
  scale_x_discrete(labels = c("f" = "Regular", "t" = "Superhost")) +
  scale_fill_manual(values = c("f" = "#A9A9A9", "t" = "#FFD700")) + # Gris y Dorado
  labs(title = "Distribucion de Precios: Superhost vs Regular",
       x = "Estatus del Anfitrion",
       y = "Precio por Noche ($)") +
  theme_minimal() +
  theme(legend.position = "none")
```

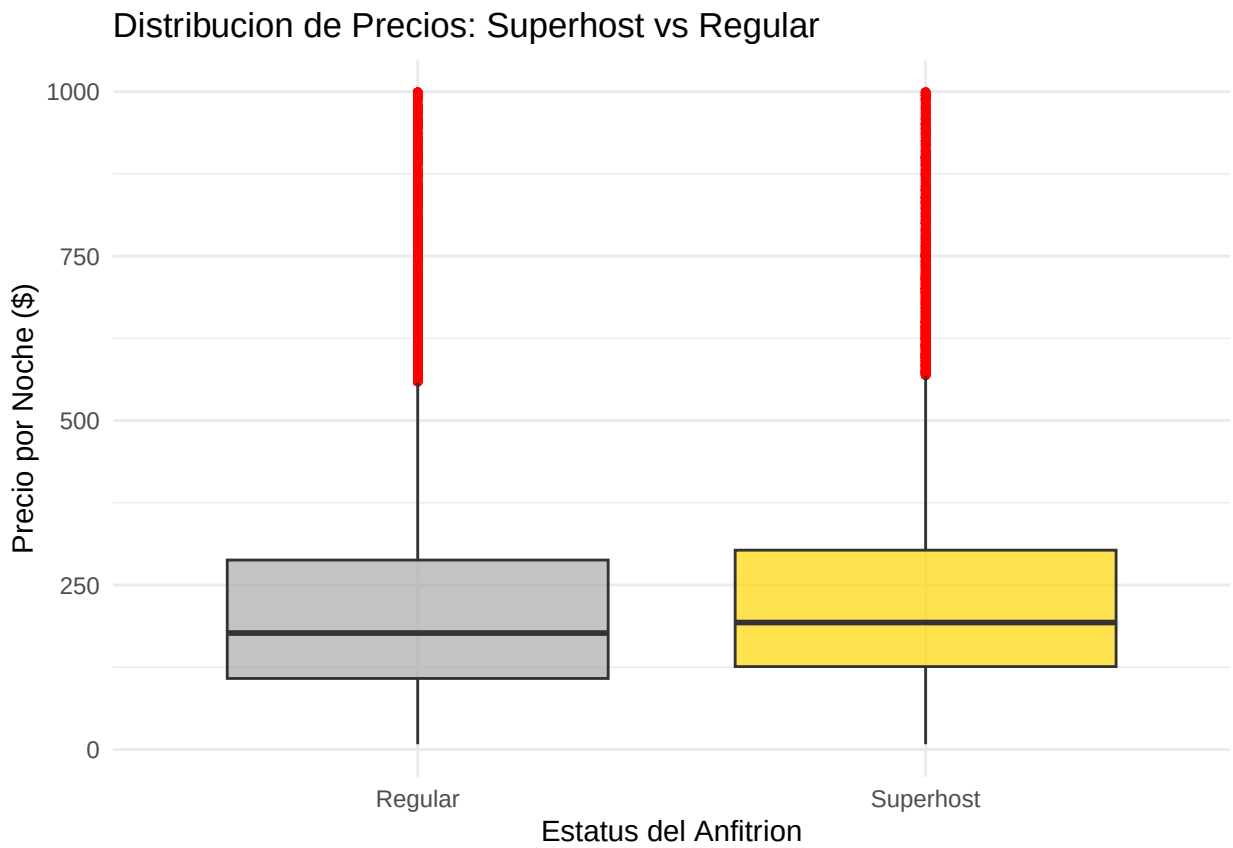

Al evaluar si la insignia de "Superhost" realmente permite cobrar más caro, el diagrama de caja nos muestra que sí hay una ventaja, pero es bastante leve. La mediana del precio por noche para los Superhosts está un poco por encima de la de los anfitriones regulares, al igual que el rango donde se concentra la mayoría de las tarifas. Esto nos indica que tener el estatus sí da un pequeño margen para subir el precio base. Sin embargo, al ver la enorme cantidad de valores atípicos en ambos grupos (los puntos rojos que llegan hasta los $1,000), queda claro que las propiedades más caras no son exclusivas de los Superhosts. Es decir, la pura insignia ayuda un poco, pero seguramente pesan mucho más factores como la ubicación premium o el tamaño de la propiedad para llegar a esos precios tan altos.

K means

```r
# --- METODO DEL CODO PARA K-MEANS ---
# 1. Preparacion de los datos (igual que antes)
datos_cluster <- listings_clean %>%
  select(price, accommodates, review_scores_rating) %>%
```

```r
  drop_na()

# 2. Escalamiento de variables
datos_escalados <- scale(datos_cluster)

# 3. Calcular la suma de cuadrados (WCSS) para k de 1 a 10
set.seed(123)
wcss <- sapply(1:10, function(k) {
  kmeans(datos_escalados, centers = k, nstart = 10)$tot.withinss
})

# 4. Crear un dataframe para graficar
codo_df <- data.frame(k = 1:10, WCSS = wcss)

# 5. Graficar el Metodo del Codo
ggplot(codo_df, aes(x = k, y = WCSS)) +
  geom_line(color = "#2E8B57", linewidth = 1) +
  geom_point(color = "#FF8C00", size = 3) +
  scale_x_continuous(breaks = 1:10) +
  labs(title = "Metodo del Codo para determinar K optimo",
       x = "Numero de Clusters (k)",
       y = "Suma de Cuadrados (WCSS)") +
  theme_minimal()
```

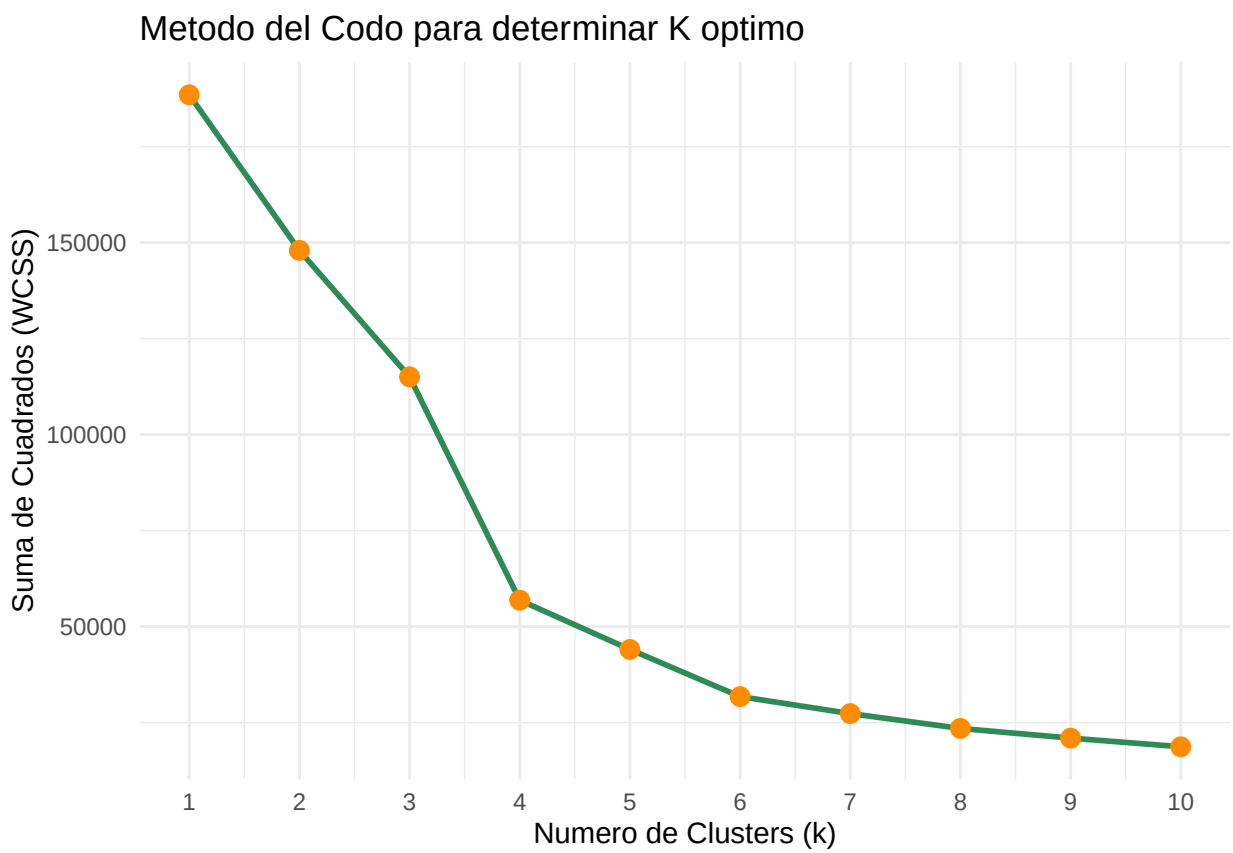

Al aplicar el Método del Codo para determinar la cantidad óptima de grupos, observamos que la suma de cuadrados dentro del clúster (WCSS) disminuye drásticamente a medida que aumentamos los grupos, pero

hace un quiebre evidente al llegar a k=4. A partir de los 4 clústeres, la curva se aplana significativamente y las reducciones en la varianza pasan a ser mínimas. Por lo tanto, determinamos que el número óptimo para segmentar las propiedades es de 4 grupos.

```r
# --- CLUSTERING CON K-MEANS (K=4) Y GRAFICA ---
# 1. Corremos el algoritmo con k=4
set.seed(123)
kmeans_result <- kmeans(datos_escalados, centers = 4, nstart = 25)

# 2. Asignamos el grupo al dataset
datos_cluster$grupo <- as.factor(kmeans_result$cluster)

# 3. Tabla resumen para interpretar los 4 grupos
resumen_grupos <- datos_cluster %>%
  group_by(grupo) %>%
  summarise(
    Cantidad = n(),
    Precio_Promedio = mean(price),
    Capacidad_Promedio = mean(accommodates),
    Calificacion_Promedio = mean(review_scores_rating)
  )

print(resumen_grupos)
```

```
## # A tibble: 4 x 5
##   grupo Cantidad Precio_Promedio Capacidad_Promedio Calificacion_Promedio
##   <fct>    <int>           <dbl>              <dbl>                 <dbl>
## 1 1        11009            613.               9.80                  4.87
## 2 2         2409            256.               4.07                  3.61
## 3 3          168          47681.               5.83                  4.63
## 4 4        49247            220.               3.76                  4.85
```

```r
# 4. Grafica de los grupos (Capacidad vs Precio)
ggplot(datos_cluster, aes(x = accommodates, y = price, color = grupo)) +
  # Usamos jitter para que los puntos no se encimen y se vea la densidad
  geom_jitter(alpha = 0.4, width = 0.3, height = 0, size = 1) +
  scale_color_manual(values = c("#FF6B6B", "#4ECDC4", "#45B7D1", "#F9CA24")) + # Paleta de colores
  labs(title = "Segmentacion de Propiedades (K-Means, k=4)",
       x = "Capacidad (Cantidad de Personas)",
       y = "Precio por Noche ($)",
       color = "Cluster") +
  theme_minimal()
```

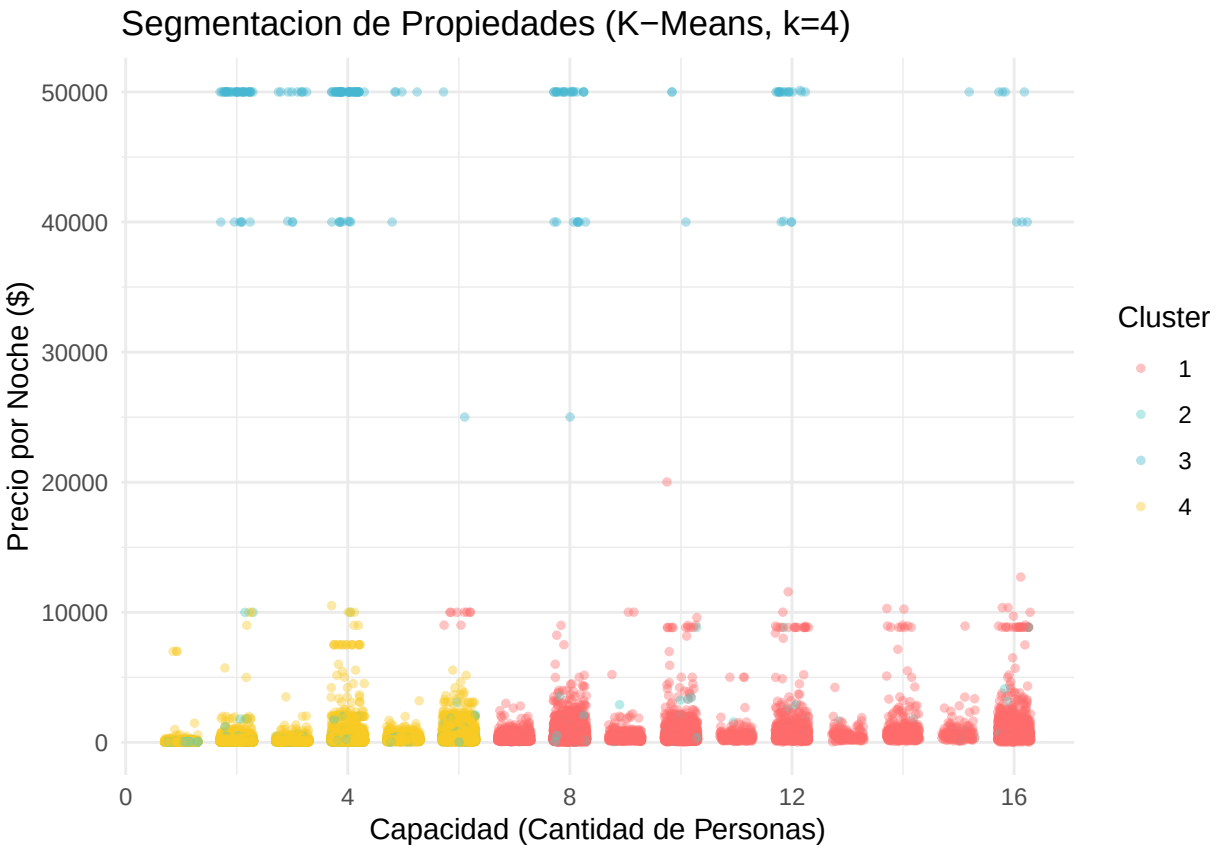

Al aplicar el modelo K-Means, logramos segmentar las propiedades en cuatro perfiles muy marcados. El Grupo 4 representa el grueso de los anuncios (más de 49 mil propiedades): son alojamientos pequeños para 3 o 4 personas, bastante accesibles con un promedio de $220 por noche y muy bien calificados (4.85). El Grupo 1 nos agrupó las opciones más grandes, ideales para familias o grupos de casi 10 personas, que obviamente cobran más (unos $613 en promedio) pero mantienen reseñas excelentes. Lo interesante salió con el Grupo 2: son alojamientos de tamaño similar a los más populares, pero claramente son las peores opciones de la plataforma porque sus calificaciones se desploman a un promedio de 3.61. Por último, el Grupo 3 aisló a los valores atípicos: un grupito de 168 propiedades de tamaño mediano pero con tarifas irreales de más de $47,000 la noche, que seguramente son alojamientos de ultra lujo o anfitriones que ingresaron mal el precio en la aplicación.